教育内容生成

课题研究方案

文档状态	实施人数	更新日期
全量范围 API 优先	1 人	2026 年 9 月 11 日

项目名称	AI-Powered Multimodal Content & Assessment Generation for Educational Applications
指导教师	Mehul Motani
项目周期	AY 2026/2027 2026 年 10 月至 2027 年 5 月
方案范围	完整四项要求 含研究设计与提前开发计划

1 研究目标与完整范围

本方案面向指导教师与项目实施者，按原选题的完整功能范围推进。目标是开发一个有课程依据、难度可控、可人工审核的多模态教学材料生成系统，并用可复现的实验评价内容质量。项目由一名学生实施；9 月提前开发，10 月起结合正式 FYP 与求职安排持续完善。

采用 API 优先路线：文字生成、嵌入、语音及图片均先调用现有服务，平台分别配置，后续再考虑模型替换。研究贡献放在课程知识检索、生成约束、难度评价、多模态一致性及实验方法上。模型训练与 GPU 部署不作为当前前置依赖。

原题模块 [1]	完整方案中的交付	验证依据
内容与考核生成	讲解、测验、课后作业；答案与解析；三档难度	固定请求可生成对应材料，教师可修改
检索增强生成	课程资料解析、向量检索、来源与版本留存	能追溯至资料页码与片段
至少两种附加模态	文字转语音与视觉辅助；实际媒体文件和学习展示	语音可播放，图片可查看，内容单独审核
教师及学生界面	教师导入、生成、编辑、审核；学生学习与练习	完成导入到学习展示的端到端流程

以上范围保留原题四项核心要求。“全量”不等于支持所有文件格式、所有学科或所有模型。先以一门课程完成有代表性的实验，再检查迁移到另一门课程的可行性。具体课程、正式考核日期和验收标准仍待导师确认；本文件不是学校批准的任务书。

原项目简介列出两人分工及 GPU 资源，但未明确要求从零训练模型。单人实施、API 优先和提前开工是本方案的实施决策；保留后续按导师意见修订的空间。

2 文献依据与研究问题

RAG 将检索到的外部资料用于生成，为知识密集型任务提供了可研究的技术路线 [2]。本项目将知识库限定为课程资料，并保存每次生成实际看到的片段。检索出相关文字并不能自动证明答案正确，因此必须把来源有效性和内容支持程度分别评价。

RAGAs 将检索上下文、忠实性及生成质量作为不同评估维度 [3]；KHANQ 对教育问题的适切性、覆盖、连贯性和复杂度进行评价 [4]。本项目借鉴其分维度评估思路，自建适合目标课程的人工量表，不直接宣称已有指标能测量学生学习增益。

研究问题	拟检验的变化	主要观察
RQ1 课程依据	不检索与课程 RAG 的比较	事实正确率、资料支持率、检索召回
RQ2 难度控制	仅难度标签与明确认知要求的比较	盲评难度匹配率、歧义和超纲比例
RQ3 多模态一致性	文字与文字加语音和图片的比较	跨模态事实一致性、可理解性及修订时间

拟形成的研究产出

形成一套从课程片段到题目与媒体的可追溯生成流程；定义可操作的难度约束和人工评价标准；通过对照实验报告改进、失败与代价。预期得到系统设计、实验数据和误差分析，而不是预先承诺准确率提升或论文发表。

语音和图片本身由外部模型生成。可主张的贡献是其与已审核文本的衔接、版本约束和一致性评价，不能把服务商模型能力描述为自主训练成果。若没有适当的学习者实验，结论限于材料质量与使用体验。

3 功能规格与验收场景

编号	功能规格	可执行验收
F01 资料	课程隔离；PDF、TXT、Markdown；页码、哈希与片段	重复导入不重复存储；扫描件明确提示
F02 检索	分块、嵌入、相似度检索；保存来源快照	更换嵌入配置后旧索引被阻止使用
F03 生成	讲解、测验和作业；选择与简答；中英文；三档难度	题量、题型、选项和引用符合请求
F04 审核	教师编辑、文字审核、版本历史	修改生成新版本并撤销其发布状态
F05 多模态	审核文字转语音和教学配图；媒体独立审核	失败可重试；旧版本媒体不进入新学习视图
F06 学习	展示已审核材料、媒体和练习解析	未审核材料不可经学习视图读取
F07 评价	人工评分、实验配置、结果导出	评分关联材料版本，保留未成功请求记录
F08 运行	异步任务、调用记录、可配置上限	失败状态可见，重复请求不会重复执行

完整交付边界

最终目标包含真实接口联调、可播放语音、可查看配图，以及教师和学生可使用的流程。第一版的本地学习视图用于开发和试用；如需多用户上线，必须补齐身份认证、课程权限和文件访问控制，不能将页面角色切换视为权限系统。

OCR、PPTX、填空题、学习进度统计和长音频分段按资料与试用反馈逐项扩展。它们是支持能力，不替代原题核心模块。首轮限制为单份 10 MB、300 页、400 个片段、每次最多 10 题；后续依据测量调整。

4 系统架构与数据流

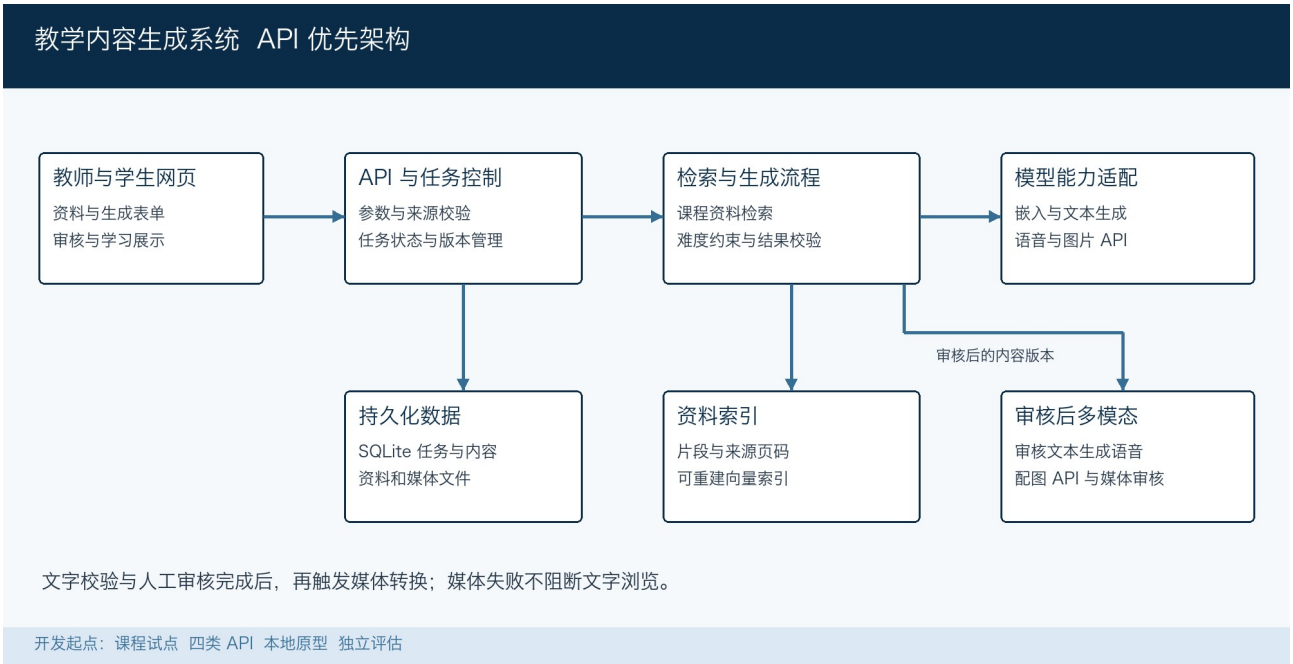


图 1 全量范围的本地开发架构

采用浏览器前端、FastAPI 后端、异步任务执行器与 SQLite 加本地文件存储。前端只提交生成要求与审核操作；后端管理课程资料、检索、模型调用、结构校验和版本。此架构适合一人开发和本机试验，跨进程任务与多实例部署留到需要时实现。

生成调用顺序

资料上传 → 文本解析与页码记录 → 分块 → 嵌入 API → 保存向量；生成请求 → 查询嵌入 → 当前课程检索 → 构造带来源的提示 → 文字 API → 结构与引用校验 → 草稿 → 人工编辑与审核 → 媒体 API → 媒体审核 → 学习展示。

检索仅在对应课程和指定资料中进行。每份材料保存实际检索片段、配置签名和提示词版本，避免资料更新后失去当时的生成依据。首版使用余弦相似度和固定 Top K；分块粒度、混合检索与重排作为后续可比较的改进项。

生成与媒体任务离开网页请求后继续执行，状态保存在数据库。运行中断的任务明确标为失败，排队任务可恢复；不自动重试不确定是否计费的网络请求。当前执行器要求单服务进程，后续多实例需要任务租约或独立队列。

5 通用 API 与数据设计

能力	首版请求与响应约定 [5–8]	配置与变化处理
文字	messages 输入；choices.message.content 中读取 JSON	独立地址、路径、密钥、模型和额外参数
嵌入	文本列表输入；带 index 的浮点向量列表	保存配置签名；变化后重建索引
语音	input、voice；MP3 二进制输出	独立配置；首版单段最多 3800 字符
图片	prompt 输入；data 中 b64_json 图片	独立配置；先支持内联 PNG、JPEG、WebP

“通用”指业务层与能力适配层分离，首版采用常见兼容协议。不同平台的鉴权、字段和返回格式仍可能不同，届时在适配层转换；不承诺任意 URL 都能直接接入。密钥放本地环境配置，不写入前端、数据库或研究材料。接口状态显示配置是否填写，不等同于已连接成功。

数据实体	主要记录	关系约束
课程与资料	课程 ID、文件哈希、页码、片段、向量签名	资料归属课程，片段归属资料
任务与调用	请求标识、参数、状态、错误、模型、usage	相同标识与参数复用任务；参数冲突拒绝
内容与修订	结构化讲解题目、来源快照、提示版本	每次编辑递增版本并回到草稿
媒体与评价	文本版本、媒体状态、模型、评分与备注	学习视图仅展示当前版本已审核媒体

6 生成策略与质量控制

课程依据与结构约束

将课程片段作为待引用数据，明确片段中的指令不构成系统指令。文字结果采用包含学习目标、讲解、题目、答案、解析、来源 ID 和视觉提示的结构化格式。校验题型、题量、选项、重复题干与引用集合；结构失败最多重新生成一次，并保留调用成本。

引用 ID 合法仅代表片段存在，不代表它支持结论。事实、答案唯一性、资料是否充分及是否超纲由人工对照检查；以后可增加模型辅助检查，但单独报告误判。模型声明资料不足时不生成可发布材料，并在任务中记录原因。

难度	生成约束	人工判定重点
基础	单一概念识别、解释或直接应用；条件完整	是否可用课程中的直接知识作答
应用	在新情境中应用或比较概念；有明确推理步骤	是否需要转换或应用知识
综合	整合概念、分析条件或论证；仍在课程范围内	难度是否来自推理而非歧义或冷门知识

文字与媒体保持一致

仅对已审核文字生成语音与图片，媒体保存对应文本版本。语音核对术语、读音、停顿和遗漏；配图核对关系、符号、文字错误和无依据细节。媒体独立审核后才能展示。修改文字会产生新版本，旧媒体需重新生成或重新核验，不能自动沿用。

文字生成中的视觉提示是中间产物；完成第二种附加模态需要实际生成并展示视觉材料。对要求精确符号的流程图，可后续增加结构化图形渲染作为可控补充。当前图片 API 路线仍保留。

API 次数上限是本地保护，不是货币预算；失败请求也计入次数。开始真实调用前先通过平台账单估算单次成本，给账户设置适当额度。后续增加延迟、字符或 token 数、单价快照和分任务成本统计。模型更换先做固定样例回归，再开展正式实验。

7 实验设计与结果报告

先选择具备使用权限的一门课程，人工确定知识点、来源范围和期望认知层级。建议用 12 个知识点开发提示与量表，另留 24 个未参与调参的知识点作测试；尽量按章节隔离，避免近似问题泄漏。以上数量是可调整的计划，不是已经收集的数据。

实验组	固定或改变的因素	用途
A	不使用课程检索，给知识点与难度标签	基础生成对照
B	加入课程 RAG，仍仅用难度标签	观察检索的影响
C	RAG 加明确认知要求与结构约束	观察难度设计的影响
D	C 加额外事实核查或修正步骤	后续消融；须单独记录修正与失败

建议正式比较 A/B/C：24 个知识点 × 3 档难度 × 3 组 = 216 份输出，每份以一道题加讲解为基本单位。先用 8 个测试点做 72 份试运行以核定标注工作量。所有组固定模型、来源池、题型、输出长度和调用设置； A 仍使用同一课程参考答案作离线评分。D 仅在实现额外核查后开展。

人工盲评正确性、资料支持度、难度匹配、答案歧义与超纲。正确性和支持度用 1–5 分及缺陷标签，难度额外选择实际档位，据此计算匹配率。邀请至少一位具备课程知识的评审；若能取得第二位，对部分样本双标并报告一致率和分歧处理。

检索用人工标注支持片段计算 Recall@K；质量同时报告所有请求的成功率、拒答率和通过条件下的评分，避免只展示成功样本。按知识点配对比较，报告均值、分布和按知识点重采样的置信区间；多次调用测量随机波动，不把题目视为完全独立样本。

多模态先抽取约 12 份已审核文字，逐项比较语音与配图的一致性、可用性和人工修订时间。若开展学生试用，采用知情参与、顺序平衡和相同内容；只有适当设计的前后测才能讨论学习成效。模型打分仅为辅助，不能替代人工金标准。

8 提前开发计划与工作量

距 10 月约三周，适合把主链路、联调记录和第一轮小实验提前做出来；不宜把整个 FYP 的学术验证都压在这三周。以下安排以每周约 20–25 小时为规划假设，遇到接口兼容或课程资料问题优先调整顺序。10 月后每周预留约 4–8 小时维护与导师反馈，实际强度由正式安排决定。

时间	阶段目标	完成标志
9 月 11–14 日	全量方案、资料导入、存储和任务骨架	文档可评审，应用能导入并查看片段
9 月 15–19 日	真实嵌入和文字联调、引用与难度	一份课程资料能生成可审核材料
9 月 20–24 日	真实语音和图片、版本与学习展示	完成两种附加模态并人工核对
9 月 25–30 日	端到端修正、评估试运行、演示记录	形成可演示版本和首批失败案例
10–11 月	导师确认、课程资料整理、实验协议定稿	正式范围及量表冻结，配合 CA1
12–2 月	系统补全、身份权限、正式实验	对照结果与误差分析可复现
3–5 月	补充验证、论文报告与演示整理	配合 CA2 和最终提交

原简介给出 CA1 的文献与设计及 RAG 文本原型方向、CA2 的完整多模态应用方向 [1]；上表月份是自主规划，具体提交日期需以课程通知为准。单人完整实施粗估 180–280 小时，包括工程、联调、评估和写作，不是课程规定工时，也不包含不可预见的资料与招募等待。

工作量主要集中在质量验证和多模态返工。先冻结一个课程与两种基础题型，做完闭环后再扩展；每周保存可演示版本、问题清单与实验记录，使 10 月面试期间的小块时间也能继续推进。

9 当前实现与后续交付

2026 年 9 月 11 日已建立第一版可运行的本地应用，包含课程与文件管理、资料分块、通用四类 API 适配、检索生成、任务记录、教师编辑与审核、媒体审核、学习视图和人工评分导出。界面及业务流程已进入开发验证阶段；尚未配置真实服务商密钥。

现有自动化测试使用隔离 HTTP 测试响应验证业务与协议，不验证真实模型质量、音频听感或图片教学价值。真实嵌入、文字、语音和图片必须在配置平台后逐项联调，再形成可作为 FYP 实验依据的数据。测试响应不提供给应用正常用户。

仍需完成	完成依据	优先级
真实 API 与课程试点	四种真实调用；完整材料人工核对	下一步
评价工具扩展	盲评标识、实际难度标签、组别与延迟记录	实验前
多用户使用能力	身份认证、课程授权、文件授权测试	对外试用前
长语音与媒体兼容	分段合成或拼接、更多响应格式	依实际材料
正式实验与报告	原始配置、失败样本、统计分析、限制	学术交付
模型替换研究	在相同协议和测试集下比较	核心交付后再决定

最终交付包括源代码及环境说明、系统与数据设计、可演示应用、原题要求对应的功能验证记录、文献综述、实验协议及结果、毕业报告和演示材料。所有数值区分实测与计划；当前没有可以报告的模型质量或学习效果结果。

下一次与导师讨论时重点确认：试点课程与资料使用条件、API 优先是否符合预期、难度定义与评审资源、单人完成四项核心要求的验收深度，以及正式节点。现阶段可以继续开发，不需要等待这些讨论才能完成基础接口和本地闭环。

10 参考资料与版本说明

[1] CEG 311 FYP 选题介绍 AY2026-2027.pdf，第 27 页。AI-Powered Multimodal Content & Assessment Generation for Educational Applications。指导教师 Mehul Motani。原始文件为本项目范围依据。

[2] Lewis et al. Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks. NeurIPS 2020. https://arxiv.org/abs/2005.11401

[3] Es et al. RAGAs: Automated Evaluation of Retrieval Augmented Generation. EACL 2024 System Demonstrations. https://aclanthology.org/2024.eacl-demo.16/

[4] Gong et al. KHANQ: A Dataset for Generating Deep Questions in Education. COLING 2022. https://aclanthology.org/2022.coling-1.518/

[5] OpenAI API Reference. Chat. https://developers.openai.com/api/reference/resources/chat

[6] OpenAI API Reference. Create embeddings. https://developers.openai.com/api/reference/resources/embeddings/methods/create

[7] OpenAI API Reference. Create speech. https://developers.openai.com/api/reference/resources/audio/subresources/speech/methods/create

[8] OpenAI API Reference. Images. https://developers.openai.com/api/reference/resources/images

在线资料核对日期：2026 年 9 月 11 日。[5–8] 仅用于说明首版兼容协议的参考格式，不代表已选择该平台或所有兼容服务都支持相同功能。模型名称、限额和价格以接入时核对结果为准。

版本记录

v0.2 全量范围 API 优先。保留原题核心要求，增加研究问题、对照实验和提前开发安排，并启动代码实现。此前 v0.1 单人任务书保留供比较；若与本版实施方向冲突，以本版为当前计划，最终以导师确认的要求为准。